嘉興大學
JIAXING UNIVERSITY
方正为人 勤慎治学

商业数据分析

题　　目：高增长低留存：Olist 用户价值与留存分析
学　　院：数据科学学院
专业班级：大数据 241
学　　号：2024459985130
姓　　名：黄喆轩
完成日期：2026.11.3

评分维度	评分要点（子项及分值）	得分
1. 数据获取合规性与清洗质量（15 分）	① 来源合规、白名单方式、合规声明完整（5）；② 数据量达标、抽样方法与随机种子说明（4）；③ 清洗完整、异常/缺失/重复处理、多表对齐（4）；④ 可导出 CSV/JSON/SQLite 复用（2）	
2. 商业分析模型应用深度（20 分）	① 模型≥3 种、选型与场景匹配（6）；② 计算正确、参数与阈值有业务依据（6）；③ 预测类含置信区间与回测误差（4）；④ 结论与模型一一对应（4）	
3. 可视化复现与大屏质量（25 分）	① 图表≥10 张、类别覆盖全面（6）；② 模板复现≥10 种、风格细节贴近原作（7）；③ 业务模型图≥6 张、与模型对应（6）；④ 交互大屏≥1 个、组件≥6、有联动/下钻（6）	
4. 代码规范性与文档完整性（10 分）	① 目录结构清晰、注释充分（3）；② README 详实、依赖明确（3）；③ 可一键复现（2）；④ 图表命名与索引规范（2）	
5. 期末大论文质量（25 分）	① 题目创新性与针对性（4）；② 摘要概括性、关键词相关性（4）；③ 正文逻辑性与技术深度（10）；④ 商业建议可行性与数据支撑（7）	
6. 创新性与商业洞察深度（5 分）	① 引入新工具/新方法（2）；② 提出有效商业建议（2）；③ 体现批判性思维（1）	
总 分	**（各维度得分相加）**	

数 据 科 学 学 院

高增长低留存：Olist 用户价值与留存分析

作者: 王海能　黄喆轩

（嘉兴大学 数据科学学院）

摘　要：巴西电商在 2016—2018 年高速扩张，但 Olist 平台客户呈现极强的一次性购买特征，规模增长与客户留存之间存在结构性矛盾。本文以 Kaggle 官方下载的 Olist 公开数据（9 张表、99,441 条订单、96,096 名客户）为对象，采用白名单下载方式合规获取，经缺失、异常、重复治理与主外键对齐后构建订单级与客户级宽表，分析窗口取 2017-01-01 至 2018-08-31（99,091 单、95,773 名客户、GMV 1,578.62 万雷亚尔）。以 RFM 八分类刻画价值结构，以同期群与二单间隔刻画留存，以帕累托/ABC 刻画收入集中度，以 ARIMA 刻画订单趋势，并将履约时效纳入解释，全部图表与大屏由 Python 生成。结果显示：一次性买家占客户数 96.89%、贡献收入 94.19%，复购客户仅 3.11%的人数、5.81%的收入，但人均消费为前者的 1.92 倍；收入最高的“重要挽留”客群占收入 38.06%且已沉默超 220 天；68.74%的复购发生在首购后 90 天内；35.44%的客户贡献 70%的收入；2018 年 1—8 月订单同比增 19.71%但月内已走平；模型 6 个月回测 MAPE 为 5.94%、RMSE 为 481.5 单；延迟交付率 6.79%，延迟组差评率 62.40%而准时组仅 9.25%。据此提出高价值首购客户二单专案、首购后 90 天四档触达、沉默客群定向召回、资源向 A 类客户与头部品类倾斜、延迟预警与周度滚动预测五条建议。

关键词：商业数据分析；RFM 模型；同期群分析；时间序列预测；交互式大屏

1 引言

1.1 研究背景

巴西电商市场在 2016—2018 年处于快速扩张期，平台型市场在连接中小卖家与消费者方面作用突出。Olist 公开数据集覆盖订单、订单商品、支付、评价、客户、商品、卖家与地理区位共 9 张表，为观察平台型电商的用户行为提供了少见的微观样本。然而，交易规模的增长并不必然意味着客户关系的深化：若增长主要依赖持续拉新，而存量客户在首购后大量沉默，则高增长背后隐藏的是获客成本上升与增长不可持续的风险。对 Olist 的统计印证了这一担忧——窗口内 95,773 名客户中仅 2,975 人（3.11%）产生过第二次购买。由此形成本文的三个问题：平台增长究竟由客户价值驱动还是由拉新驱动？一次性买家占主导是留存策略整体失效，还是存在被平均数掩盖的可挽救子群体？履约体验与满意度、沉默之间是否存在可检验的关联？

1.2 研究目的

本文的目的有四：一是以白名单方式合规获取 Olist 多表数据，完成缺失、异常、重复治理与主外键对齐，形成可复用的订单级与客户级宽表；二是用 RFM 八分类、同期群与二单间隔、帕累托/ABC、ARIMA 四个模型，从“价值结构—留存规律—收入集中度—趋势可持续性”四个层面刻画高增长低留存现象；三是把履约时效纳入解释，回答“客户为什么不再来”；四是用 Python 复现可视化模板、绘制业务模型图并搭建交互式大屏，最终提炼出有数据支撑、可落地的商业建议。

1.3 研究意义

理论上，本文将用户价值分层、同期群留存与时间序列预测置于同一平台型电商数据集联合使用，形成“结构—机制—趋势”的递进证据链，而不是四个互不相干的分析并列；其中“F 维度因中位数为 1 而改用二值划分”“以回

测误差而非 AIC 选型”两处处理，对小样本电商数据分析具有方法参考价值。实践上，若收入高度依赖一次性买家，运营资源就应从“泛会员体系”转向“高价值首购客的二单转化”；若复购集中在首购后 90 天内，召回预算就应前移至第一个季度，而不是平均分布在整个生命周期。方法上，全部图表与大屏由 Python 生成、指标与图表由同一份代码产出，流程可复现、可导出，可为同类电商分析提供工程化范式。

2 数据准备与预处理

2.1 **数据源介绍（名称、URL、规模、字段说明）**

数据源为 Brazilian E-Commerce Public Dataset by Olist，来源于 Kaggle 公开数据集（https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce），记录 2016 年 9 月至 2018 年 10 月的匿名化交易信息，共 9 张表：订单、订单商品、客户、支付、评价、商品、卖家、地理区位与品类翻译。表 1 给出各表的记录数、主键与用途。公开版本含 99,441 条订单、112,650 条订单商品明细、32,951 个商品、3,095 个卖家，覆盖巴西 27 个州、4,119 个城市，主表规模远超课程“不少于 500 条”的要求。

表 1　数据表规模与主键

数据表	记录数	主键	说明
olist_orders_dataset	99,441	order_id	订单主表：状态、下单/审批/发货/送达/承诺送达时间
olist_order_items_dataset	112,650	order_id + order_item_id	订单商品明细：卖家、价格、运费，笔均 1.14 件
olist_customers_dataset	99,441	customer_id	客户与地域；customer_unique_id 为跨订单真实客户标识
olist_order_payments_dataset	103,886	order_id + payment_sequential	支付方式、分期数与支付金额，一单可多条
olist_order_reviews_dataset	99,224	review_id	评价得分与评论文本，按订单去重后一单一条
olist_products_dataset	32,951	product_id	品类名称、重量与尺寸属性
olist_sellers_dataset	3,095	seller_id	卖家及其所在地区
olist_geolocation_dataset	1,000,163	zip_prefix + 经纬度	邮编前缀近似坐标，仅用于地图展示
product_category_name_translation	71	product_category_name	品类葡英对照

2.2 合规获取方式（白名单方式说明：官方下载文件 / Python 数据接口库）

本文采用课程白名单中的“官方下载文件”方式：登录 Kaggle 数据集主页通过 Download 按钮一次性下载官方 ZIP，解压得到 9 个 CSV。全过程未使用 Scrapy、Selenium、requests 网页解析或模拟登录等任何爬虫手段，也未使用第三方镜像、转存或网盘副本。原始 CSV 留存于 data/raw/，清洗与派生结果另存 data/clean/，清洗脚本随仓库提供，任何人均可从官方原始文件重新生成全部中间结果，保证过程可追溯、结果可复核。

2.3 数据来源合规声明（获取日期、授权/License）

获取日期为 2026 年 10 月 30 日；授权协议为 CC BY-NC-SA 4.0（署名—非商业性使用—相同方式共享）。本文仅将该数据用于嘉兴大学《商业数据分析》课程期末大作业的学术分析与教学演示，不用于任何商业目的；在论文、README 与代码仓库中明确署名 Olist 与 Kaggle；派生指标、统计结果与图表如对外呈现，以相同方式共享。数据为匿名化交易记录，不含姓名、证件号、手机号等可直接识别个人身份的信息，本文只做聚合统计与建模，不进行个体

重新识别。

2.4 数据集概述（主表/维度表结构、主外键关系）

以订单表为事实主表，其余表围绕订单或客户关联，构成星型结构。关联中有一个必须点明的关键点：**客户表的 customer_id 是订单级标识（99,441 个，与订单数一一对应），customer_unique_id 才是跨订单的真实客户标识（96,096 个）**。若按 customer_id 统计购买频率，Frequency 恒为 1，复购率会被错误地算成 0，整篇结论随之失真。因此本文所有客户级指标（F 值、留存、RFM、同期群）一律按 customer_unique_id 聚合。

其余关联关系为：订单商品表按 order_id 与订单表一对多，连接后粒度为订单项，订单数与客户数须用去重计数避免重复；支付表一单可有多条记录，先按 order_id 聚合再连接；评价表去重后一单至多一条；地理表按邮编前缀关联，仅用于地图；商品表经品类名称连接翻译表得到英文品类。分析主路径为“客户（customer_unique_id）→订单→订单商品→商品/卖家”，支付与评价按订单聚合后左连接。

3 数据清洗与治理

3.1 数据清洗（缺失值、异常值、重复值处理）

缺失值处理：订单表 order_approved_at 缺失 160 条、order_delivered_carrier_date 缺失 1,783 条、order_delivered_customer_date 缺失 2,965 条，主要对应未发货、未送达或取消订单，属业务状态缺失而非录入错误，故不插补、不删除，在履约时效分析中按“未交付”单独标记，避免把未完成订单误判为延迟。商品表 product_category_name 缺失 610 条，统一填充为 unknown 并单列展示，不并入任何真实品类。评价表的评论文本缺失率虽高，但本文仅使用 review_score，该字段完整无缺。

异常值处理：金额类字段采用 IQR 法识别：payment_value 的四分位为

62.01 与 176.97，上界 349.41，超出者 7,866 条（占 7.91%）；99 分位为 1,075.79，最大单笔 13,664.08。对这些记录不直接删除，而是在金额类分析中改用 1%与 99%分位缩尾（winsorize），避免极端订单拉偏均值；订单量、客户数等计数型 KPI 不受缩尾影响。日期字段核查未发现“送达早于下单”的逻辑异常（0 条）。订单状态中 delivered 占 97.02%，canceled 0.63%、unavailable 0.61%、shipped 1.11%等其余状态单独统计占比，不进入 RFM 与留存计算。

重复值处理：订单表 order_id 唯一，无重复。评价表存在同一 review_id 对应多条记录的情况（涉及 1,603 行、814 条多余记录），按 order_id 去重并保留 review_creation_date 最新的一条，保证一单一条评价。地理表 100 万条记录按邮编前缀聚合后保留组内中位数经纬度，仅用于地图展示，不参与金额与客户级计算。

3.2 数据转换（类型统一、日期对齐、指标派生）

类型统一：下单、审批、发货、送达、承诺送达、评价创建等时间字段统一转换为 datetime64；金额字段统一为 float64 并保留两位小数；邮编前缀统一为字符串，避免前导零丢失；order_item_id、payment_installments 转为整型；订单状态、品类名称统一转为分类变量。

日期对齐：原始时间跨度为 2016-09 至 2018-10，但 2016 年订单极少（9 月 4 单、12 月 1 单）、2018 年 9—10 月仅 16 单与 4 单且交付信息不完整。为保证各月口径完整，将 RFM、留存与预测的主分析窗口统一截取为 2017-01-01 至 2018-08-31（20 个完整月份），两端不完整月份不进入时间序列；全量数据仍保留用于描述统计与表 1 的规模说明。

指标派生：派生字段包括：delivery_days（下单至送达天数）、delay_days（实际送达减承诺送达，正值表示延迟）、is_late（延迟二值标记）、order_total_value（商品金额加运费）、item_count（订单项数）、purchase_year/month/ym（年月）、cohort_month（按 customer_unique_id 首次购

买月份生成的同期群标签）。派生字段全部在清洗脚本中一次性生成并随宽表落盘，后续模型不复算，避免口径漂移。

3.3 数据整合（多表关联逻辑、抽样方法与随机种子）

多表关联逻辑：以订单表为主表，按 order_id 左连接订单商品、支付、评价；订单商品再左连接商品与卖家；客户表通过 customer_id 连接订单表，并保留 customer_unique_id 作为客户主键。支付表先按 order_id 聚合（金额求和、分期数取最大值、支付方式取众数）再连接，防止一单多支付导致订单行膨胀；评价表先去重再连接；关联完成后按 order_id 去重还原订单粒度，再按 customer_unique_id 聚合生成客户粒度表。主外键一致性核查显示：订单表与客户表 customer_id 完全匹配；订单商品表 order_id 为订单表子集（部分取消或不可用订单无商品项），属正常业务关系，不做强制过滤。

抽样方法与随机种子：订单主表 9.9 万条，规模适中且满足课程要求，本文全量使用、不做抽样；仅在图 4-1 的 RFM 散点展示中对每类客户做最多 1,500 点的等量抽样以保证渲染速度，抽样随机种子 random_state=42 并在代码中注明，不改变任何统计结果。清洗结果导出为 CSV（orders_clean、customers_clean、order_items_clean 等），同时提供 SQLite 版本 olist.db，便于他人直接复用与核对。

4 商业分析模型

4.1 模型选型（≥3 种：如 RFM、同期群、波士顿矩阵、关联规则、SARIMA 等）

围绕“高增长与低留存并存”这一核心矛盾，本文选用 4 种模型，并以履约分组对比作为机制解释的补充，形成“价值结构—留存规律—收入集中度—趋势可持续性—流失原因”的递进分析链（表 2）。

表 2　模型选型与对应问题

模型	回答的问题	核心输出	章节
RFM 八分类	收入主要由哪类客户贡献	八分类客户数与收入占比、人均消费	4.3
同期群 + 二单间隔	留存何时衰减、二单何时发生	留存矩阵、累计复购率、间隔分布	4.3
帕累托 / ABC 分类	收入是否集中于少数客户与品类	累计收入曲线、ABC 分组、品类集中度	4.3
SARIMA / ARIMA	订单趋势是否可持续	点预测 + 95%置信区间、MAPE/RMSE	4.3
履约分组对比	延迟是否压低满意度	评分均值、中位数与差评率差异	4.3

4.2 参数与阈值设定依据

RFM 模型：R 为最近一次购买距分析截止日（2018-08-31）的天数，F 为按 customer_unique_id 统计的订单数，M 为客户累计支付金额。R 与 M 以中位数切分（R 中位数 220 天、M 中位数 107.27 雷亚尔），理由是窗口内两指标均呈右偏分布，中位数既能平衡高低两组样本量，又不受极端订单影响。F 不采用中位数：Olist 一次性买家占绝对多数，F 的中位数为 1，用中位数切分会使 F 维度完全失去区分度，故改用“F=1（一次性）与 F≥2（复购）”的二值划分——这一调整本身是对数据特征的响应，也是本文与通用 RFM 模板的差异点。三个维度各分高低，组合为重要价值、重要保持、重要发展、重要挽留、一般价值、一般保持、一般发展、一般挽留 8 类客户。

同期群分析：以 customer_unique_id 首次购买月份为同期群标签（cohort_month），统计各群在首购后第 k 个月（k=0...12）仍有订单的客户比例，留存率=该月有复购的客户数/该群初始客户数；对尚未观测满 k 个月的同期群留空，不参与该月加权平均，避免新生同期群拉低整体留存。同时计算二单间隔（首购至第二单的天数），刻画复购发生的时间分布。

帕累托 / ABC 分类：按客户累计 M 降序排列计算累计收入占比，累计占比≤70%为 A 类、70%—90%为 B 类、>90%为 C 类；70%/90%沿用帕累托法则的常用业务口径，并在结果中检验实际集中度是否偏离经典 80/20，若偏离则

据实说明，不硬套法则。

时间序列模型：以 2017-01 至 2018-08 的 20 个月度订单量为序列。ADF 检验显示原序列不平稳（p=0.1995）、一阶差分后平稳（p<0.001），故取 d=1；季节差分在本样本上会使有效观测降至 8 个以下，季节项无法稳定估计（多次试算出现不收敛或预测发散），故最终保留非季节 ARMA 项，即 $SARIMA(1,1,1)(0,0,0)_{12}$。选型不以 AIC 最小为唯一标准：在 20 个观测下 AIC 偏向参数更多的模型，本文以 6 个月回测 MAPE 为主、AIC 与参数节约定律为辅，并与随机游走、3 期移动平均、季节朴素三个基准对照。

履约指标：以承诺送达日为基准定义延迟（delay_days>0），延迟率=延迟订单数/已送达订单数；按是否延迟分组比较评价得分，均值、中位数、1—2 分差评率与 5 分率四项指标同时报告，避免单一均值掩盖分布差异。

4.3 模型计算与验证（预测类含置信区间与回测误差 MAPE/RMSE）

RFM 结果：95,773 名客户落入 8 类（表 3）。最直接的事实与通用 RFM 模板的预期相反：F=1 的客户 92,798 人、占 96.89%，贡献收入 94.19%；复购客户仅 2,975 人、占 3.11%，贡献收入 5.81%。收入几乎完全由“只买一次的人”带来，复购并未成为收入支柱。复购客户人均消费 308.23 雷亚尔，是一次性客户（160.23 雷亚尔）的 1.92 倍、人均订单 2.12 笔（最高 17 笔），但体量太小，短期内无法承担增长引擎的角色。M 高于中位数的 47,891 名客户贡献 81.05% 的收入，其中 45,306 人（94.6%）只购买过一次、22,985 人（48.0%）最近一次购买距今已超过 220 天。收入占比最高的单一客群是“重要挽留客户”（R 低、F=1、M 高）：22,985 人、占客户数 24.00%、贡献 38.06%的收入，人均 261.36 雷亚尔；紧随其后的是“重要发展客户”（R 高、F=1、M 高），22,321 人、23.31%的客户数、37.38%的收入。两者合计 45,306 人（47.31%）贡献 75.44%的收入。而“又高又稳”的重要价值客户仅 1,152 人（收入 2.48%）、重要保持客户 1,433 人（收入 3.13%），合计 2,585 人、占客户数 2.70%、贡献 5.61%收入。

表 3　RFM 八分类客户结构与收入贡献

客群	客户数（人）	客户占比（%）	收入（万雷亚尔）	收入占比（%）	人均消费（雷亚尔）
重要挽留客户	22,985	24.00	600.74	38.06	261.36
重要发展客户	22,321	23.31	590.16	37.38	264.40
一般发展客户	24,434	25.51	152.02	9.63	62.22
一般挽留客户	23,058	24.08	144.00	9.12	62.45
重要保持客户	1,433	1.50	49.42	3.13	344.87
重要价值客户	1,152	1.20	39.18	2.48	340.10
一般保持客户	198	0.21	1.58	0.10	79.88
一般价值客户	192	0.20	1.52	0.10	79.11
合　计	**95,773**	**100.00**	**1,578.62**	**100.00**	**164.83**

同期群结果：各同期群的留存曲线落差很小：首购后第 1 个月留存率 0.51%，第 3 个月 0.26%，第 6 个月 0.23%，第 12 个月 0.18%——不是“某节点急剧衰减”，而是从第一个月就处在 1%以下的低位并缓慢走平。累计口径下，可观测满 3 个月的客户中仅 1.31%产生过复购，满 6 个月 1.99%，满 12 个月 3.35%。二单间隔给出了更可操作的信息：2,975 名复购客户的首购—二单间隔中位数为 27.9 天，51.09%在 30 天内、61.78%在 60 天内、68.74%在 90 天内、82.96%在 180 天内完成（表 4）。该结果修正了“留存随时间衰减”的直觉：Olist 的问题不是老客慢慢流失，而是绝大多数客户从未被激活为二次购买者，留存抓手应在首购后的第一个季度。

表 4　同期群留存与二单间隔

指标	数值	指标	数值
首购后第 1 个月留存率	0.51%	首购后第 6 个月留存率	0.23%
首购后第 3 个月留存率	0.26%	首购后第 12 个月留存率	0.18%
3 个月累计复购率	1.31%	6 个月累计复购率	1.99%
12 个月累计复购率	3.35%	二单间隔中位数	27.9 天
90 天内完成二单占比	68.74%	180 天内完成二单占比	82.96%

帕累托与 ABC 结果：按客户累计消费金额降序，35.44%的客户贡献 70%的收入，66.28%贡献 90%，收入最高的 10%客户贡献 38.51%。以 70%/90%划分，A 类 33,941 人（35.44%）、B 类 29,539 人（30.84%）、C 类 32,293 人（33.72%）。与经典 80/20 相比，Olist 的集中度略低（并非“20%客户贡

献 80%收入”），但仍显著偏离绝对平均线：A 类客户以约三分之一的人数贡献七成收入。品类维度同样集中，71 个有效品类中前五为 health_beauty（9.26%）、watches_gifts（8.87%）、bed_bath_table（7.63%）、sports_leisure（7.27%）、computers_accessories（6.71%），前十合计 62.36%，需 18 个品类才覆盖 80%收入。

SARIMA 结果与回测：候选模型的 AIC 与回测误差见表 5。AIC 最小的 ARIMA(2,1,2)（AIC=172.84）在回测中 MAPE 高达 33.28%，是参数过多导致的典型过拟合；ARIMA(1,1,1)（AIC=190.38）的回测 MAPE 为 5.94%、RMSE 为 481.5 单，残差 Ljung-Box 检验 p=0.749（无显著自相关），故最终采用后者。6 个月（2018-03 至 2018-08）逐月误差在 0.59%—12.52%之间，2018 年 5—7 月实际值低于预测，反映下半年的走弱。与朴素基准对比，随机游走 MAPE 为 5.20%、3 期移动平均为 5.07%，均略优于本文模型；季节朴素因 2017 年同期基数过低，误差达 48.54%。这说明在平坦期简单方法已足够好，ARIMA 的价值在于给出可解释的区间与结构，而非把点预测做得更准。全样本重估后，2018 年 9—11 月的点预测为 6,428、6,483、6,447 单，95%置信区间分别为 [4,683, 8,173]、[4,516, 8,450]、[3,996, 8,897]，三个月合计约 19,358 单；区间宽度约为点预测的 ±27%，故结论应表述为“订单量维持在 6,000—7,000 单的平台区间”，而非精确排产依据。模型无法刻画 2018 年 11 月的黑五脉冲（2017 年 11 月曾环比增长 62.90%），该缺口应由大屏的事件标注或引入促销虚拟变量补足。

表 5　预测模型候选与 6 个月回测结果

模型	AIC	MAPE（%）	RMSE（单）	结论
ARIMA(1,1,1)	190.38	5.94	481.5	采用：误差最小且参数最省
ARIMA(2,1,2)	172.84	33.28	2,403.5	AIC 更优但明显过拟合
ARIMA(1,1,1)$(0,0,1)_{12}$	8.00	5.59	445.4	AIC 不可比（季节项占用有效样本）
SARIMA(1,1,1)$(1,1,1)_{12}$	—	—	—	季节差分后有效观测不足，不收敛
随机游走（基准）	—	5.20	376.5	平坦期已足够好
3 期移动平均（基准）	—	5.07	386.9	平坦期已足够好
季节朴素（基准）	—	48.54	3,405.3	基数过低，严重高估

履约验证：在 96,203 笔有完整送达时间的已送达订单中，平均配送 12.07 天、中位 10 天、90 分位 23 天；以承诺送达日为准，延迟订单 6,378 笔，延迟率 6.79%，延迟订单平均晚 10.62 天。按是否延迟分组，准时组 89,182 笔的均分 4.291、中位 5 分、1—2 分差评率 9.25%、5 分率 62.28%；延迟组 6,378 笔的均分仅 2.271、中位 1 分、差评率 62.40%、5 分率 16.56%，其中给 1 分的比例高达 53.80%，是准时组 6.60%的八倍。该差距大于本文考察的任何其他变量，说明履约时效是满意度的主导因素。需要说明的是，这是相关而非因果：延迟可能与偏远地区、大件商品、卖家发货慢等因素共变；但延迟发生在评价之前、时序方向明确，将其作为留存治理的配套抓手是合理的。

5 Python 数据分析与可视化

5.1 数据探索性分析

在进入模型之前，先对窗口内数据做描述统计与结构探查（表 6）。窗口内共 99,091 笔订单、95,773 名客户，GMV 合计 1,578.62 万雷亚尔，客单价 159.31 雷亚尔、笔均 1.14 件商品。支付结构高度集中：信用卡占 76.56%、boleto（巴西本地银行票据）19.90%、代金券 2.01%、借记卡 1.54%，平均分 2.93 期。地域上圣保罗州（SP）贡献 42.00%的订单，RJ、MG、RS、PR 依次为 12.91%、11.70%、5.49%、5.07%，前五州合计 77.17%，呈“一超多强”格局——物流与客服资源的边际收益在东南部最高，也说明平台对单一区

域依赖较强。整体评分均值 4.086，5 星占 57.77%、1 星占 11.52%，呈现明显的两极分布，为后续履约分析埋下伏笔。

表 6　主要经营指标（窗口：2017-01-01—2018-08-31）

指标	数值	指标	数值
订单数（单）	99,091	客户数（人）	95,773
GMV（万雷亚尔）	1,578.62	客单价（雷亚尔）	159.31
笔均件数（件）	1.14	平均评分（分）	4.086
平均配送时长（天）	12.07	中位配送时长（天）	10
配送时长 P90（天）	23	延迟交付率（%）	6.79
信用卡支付占比（%）	76.56	前五州订单占比（%）	77.17

5.2 可视化模板复现（对照《Excel 数据可视化》≥10 种）

对照《Excel 数据可视化——从图表到数据大屏》的 30 种模板，本文用 Matplotlib 复现 12 种（满足“≥10 种”要求），覆盖柱形、折线、饼环极坐标、仪表盘与滑珠四类：柱形/条形类 5 张（渐变柱形、带均值柱形、渐变圆角柱形、标注柱形、蝴蝶图）、折线/走势类 3 张（平滑折线、菱形走势、对比折线）、饼环与极坐标类 2 张（单值圆环、玉玦）、仪表盘与滑珠类 2 张（仪表盘、滑珠）。复现遵循“类型一致、布局贴近、配色统一、标签图例对应、标题单位完整”五项原则，统一 200 dpi、统一命名 fig01—fig26。

模板原本使用虚拟数据，本文改用 Olist 真实指标承载，使复现图同时具备业务含义：fig01 为 2017 年月度 GMV、fig02 为 TOP10 州订单量与均值、fig03 为 TOP8 品类收入、fig04 为支付方式结构、fig06 为 2017 与 2018 同月订单量双向对比、fig10 为月度订单量平滑趋势、fig11 为月度准时交付率、fig12 为两年同期订单量对比、fig13 为一次性买家占比、fig16 为品类收入占比的玉玦图、fig19 为准时交付率仪表盘、fig26 为 RFM 八分类收入占比滑珠图。逐图如下。



图 5-1　渐变柱形图（fig01）：2017 年月度 GMV

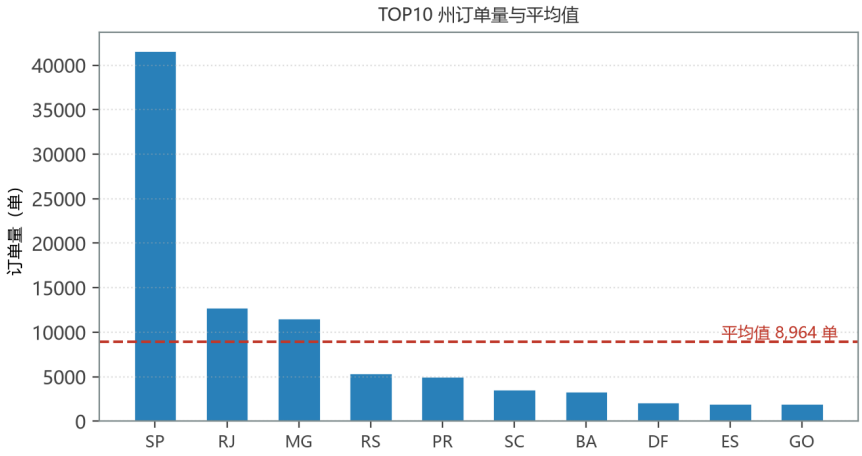


图 5-2　带均值柱形图（fig02）：TOP10 州订单量与均值线

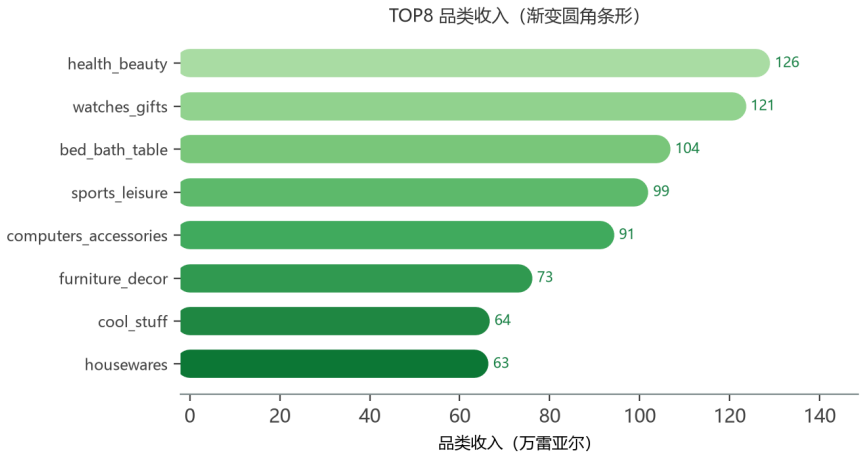


图 5-3　渐变圆角柱形图（fig03）：TOP8 品类收入

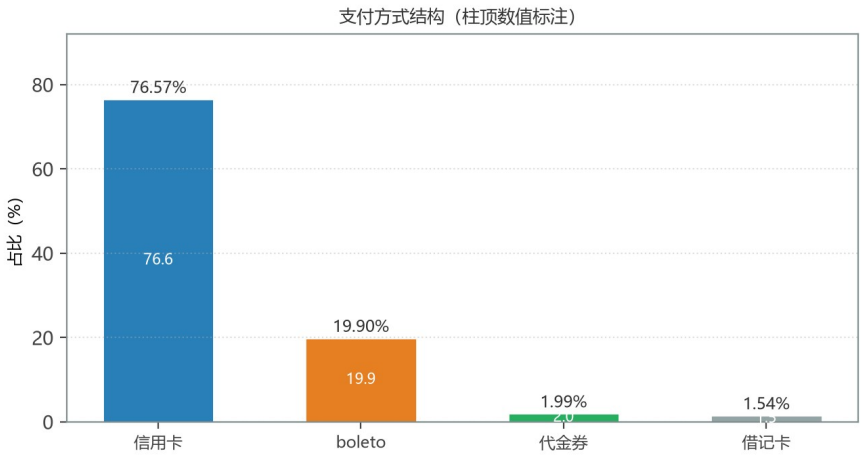


图 5-4　标注柱形图（fig04）：支付方式结构

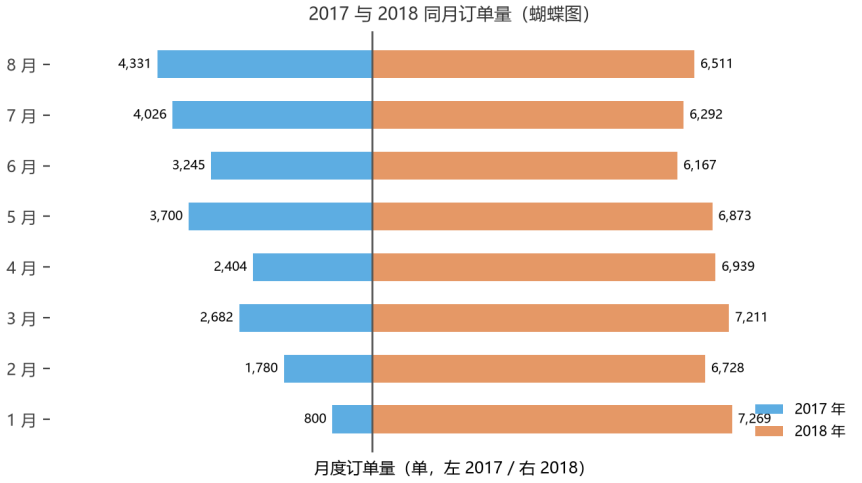


图 5-5　蝴蝶图（fig06）：2017 与 2018 同月订单量对比



图 5-6　平滑折线图（fig10）：月度订单量样条插值



图 5-7　菱形走势图（fig11）：月度准时交付率

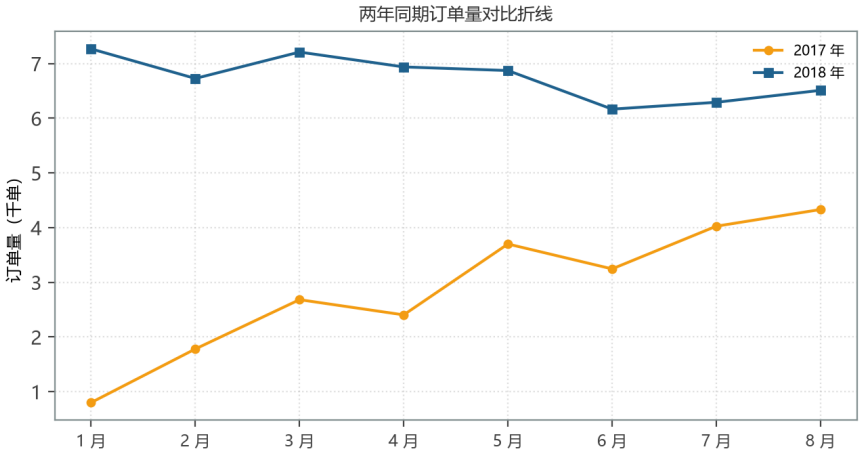


图 5-8　对比折线图（fig12）：两年同期订单量

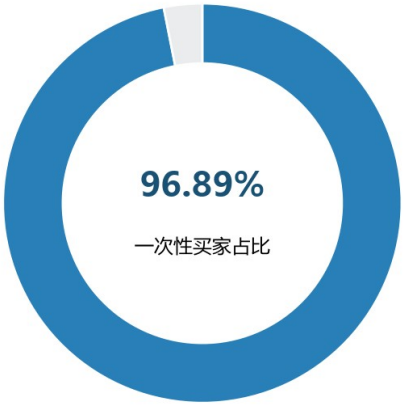


图 5-9　单值圆环图（fig13）：一次性买家占比 96.89%



图 5-10　玉玦图（fig16）：TOP8 品类收入占比

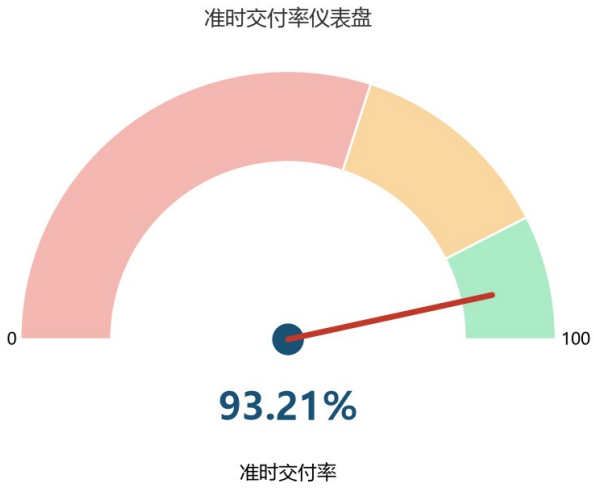


图 5-11　仪表盘图（fig19）：准时交付率 93.21%

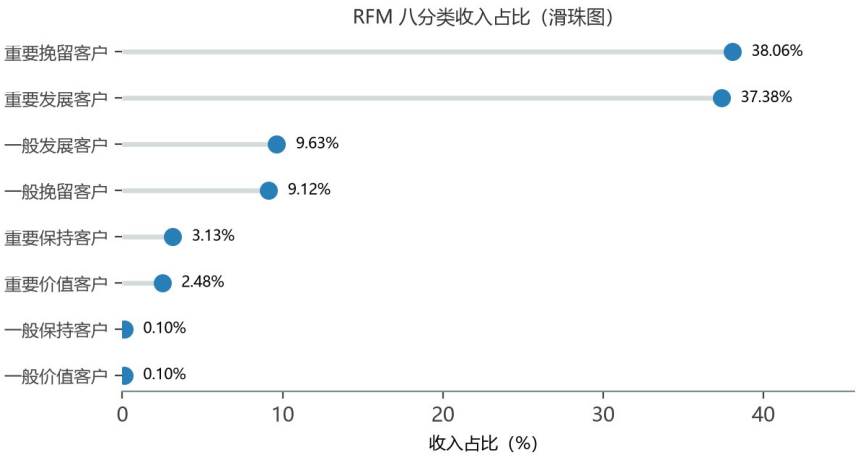


图 5-12　滑珠图（fig26）：RFM 八分类收入占比

与 Excel 实现相比，Python 版的数据与图表分离，渐变、双轴、置信区

间均由参数控制，可一键批量导出，适合重复出图与口径一致的批量复现；不足是圆角柱形的圆角半径、艺术化填充只能近似（本文改用圆端粗线模拟圆角，见 fig03），视觉精细度略低于原模板，但图表类型、布局结构、配色逻辑与信息表达与原模板一致。

5.3 业务模型图（≥6 张，与第 4 章模型对应）

业务模型图共 6 张，与第 4 章所选模型一一对应：RFM 价值分布散点与八分类收入贡献对应 RFM 模型，同期群留存热力图对应同期群模型，客户收入帕累托曲线对应帕累托/ABC，订单量回测与预测对应时间序列模型，准时与延迟交付评分构成对应履约分析。逐图解读如下。

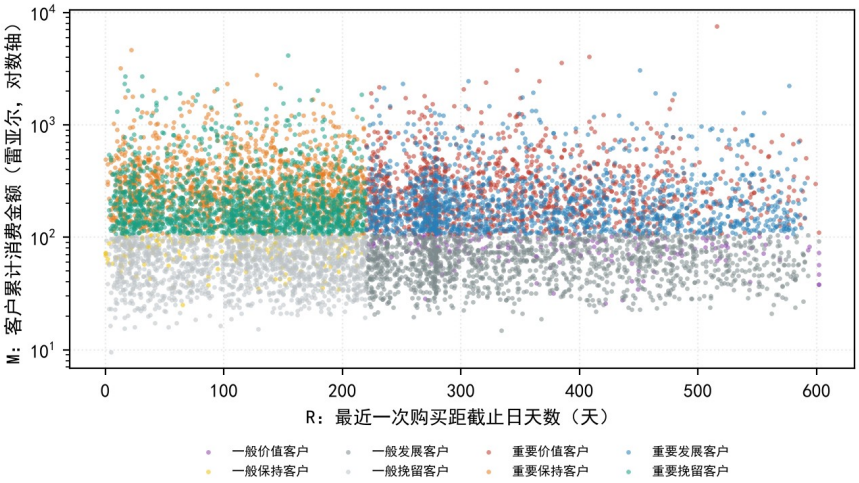


图 5-13　RFM 客户价值分布（R×M，按八分类着色）

图 5-13 横轴为 R（天数，越靠左越近期有购买）、纵轴为 M（对数轴）。高 M 区域（10^2 雷亚尔以上）几乎被红、橙、蓝、青四色覆盖，其中红（重要价值）与橙（重要保持）集中在左侧近期区，蓝（重要发展）与青（重要挽留）铺满整条 R 轴——高价值客户并不稀缺，稀缺的是“近期且复购”的那一小块；灰色系（一般客群）占据 M 中位数以下，人数最多但收入贡献不足 10%。

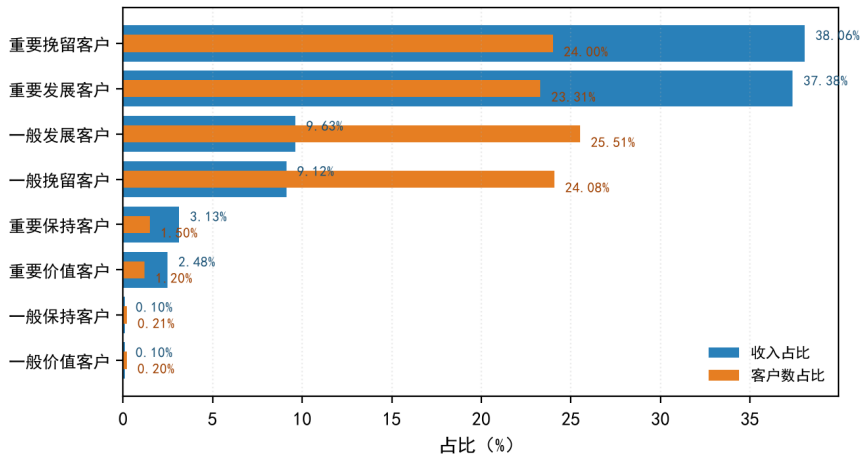


图 5-14　RFM 八分类的客户数占比与收入贡献

图 5-14 把人数结构转换为收入结构：条形长度差直观显示“重要挽留”与“重要发展”两个一次性高客单客群合计贡献 75.44%收入，而人数占比过半，说明按人数配置资源会系统性错配。

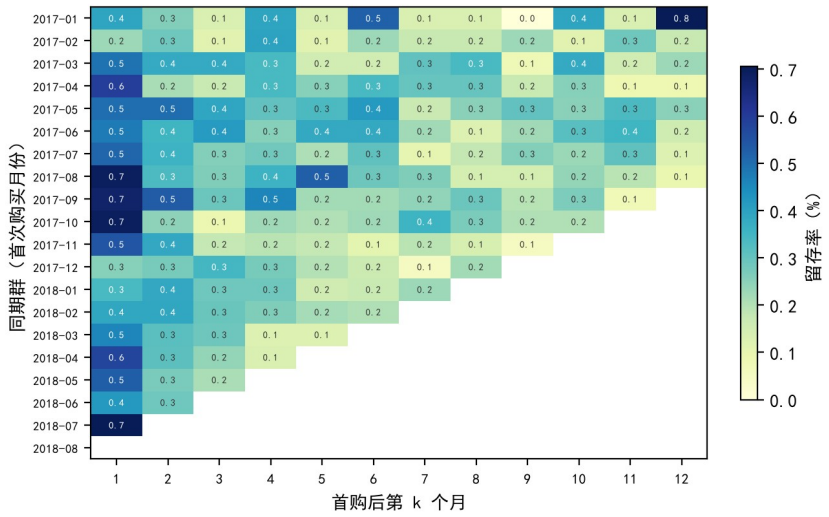


图 5-15　同期群留存热力图（第 0 月为同期群基数，故省略）

图 5-15 行为同期群、列为首购后月数。可见整片色块都在 1%以下的浅色区间，相邻列落差很小，没有出现“某月断崖”的结构；2017 年早期同期群的色阶略深于 2018 年，与复购率随时间小幅改善一致，但量级仍不足以改变结论。

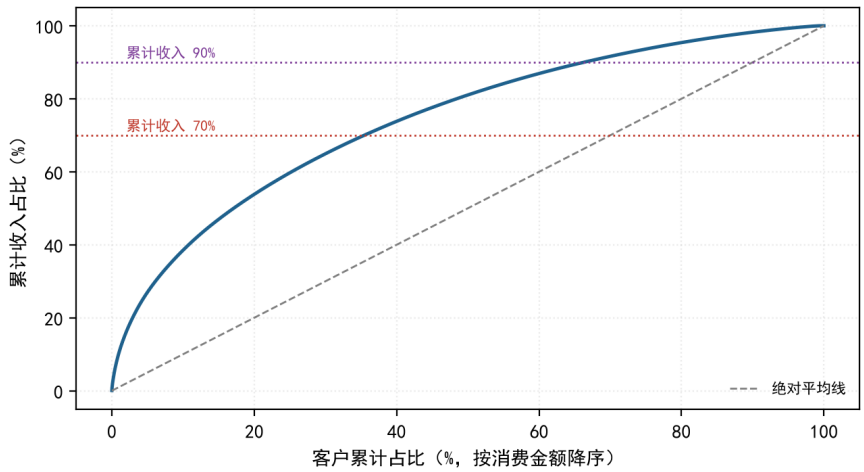


图 5-16　客户收入帕累托曲线（70%/90%阈值）

图 5-16 的曲线明显高于绝对平均线、低于经典 80/20 的理想帕累托线：70%收入由 35.44%客户贡献，90%收入由 66.28%客户贡献。运营含义是 A/B/C 三类客户都需分层策略，不能只盯头部。

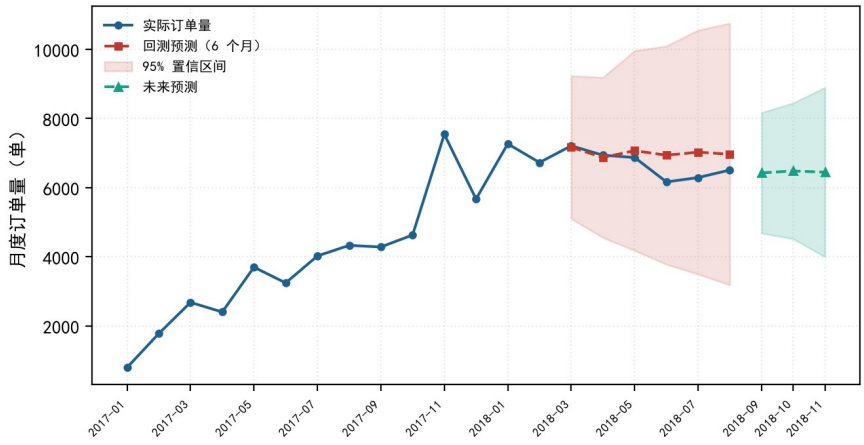


图 5-17　订单量 6 个月回测与未来 3 个月预测（含 95%置信区间）

图 5-17 中实线为实际值、红色虚线与阴影为 2018-03 至 08 的回测值与 95%区间、绿色为未来 3 个月预测。回测段预测略高于实际，虚线与实际的偏离集中在下半年，正是“增长走平”的图形证据；预测区间宽（约±27%）说明该模型只宜作区间预警。

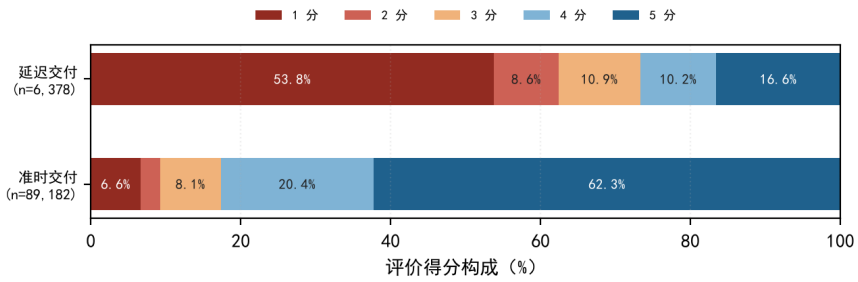


图 5-18　准时与延迟交付的评价得分构成（%）

图 5-18 用 100%堆叠条形图而非箱线图：评价得分是 1—5 的定序变量，箱线会把“中位 5 分、四分位 4—5 分”压成一个方块，堆叠图则一目了然地显示延迟组 53.80%给 1 分、准时组仅 6.60%，差异集中在最低分而非整体平移。

5.4 交互式可视化大屏（Pyecharts/Streamlit/Dash；组件≥6、联动说明；全 Python 实现，未使用 Power BI/Tableau）

大屏使用 Streamlit 搭建，含 7 类组件，满足“≥6 个组件”的要求：KPI 卡（订单数、客户数、GMV、客单价、延迟率、复购率）、月度订单趋势图、RFM 八分类结构图、同期群留存热力图、州级地理分布图、筛选器（州/日期范围/RFM 分层多选）与订单明细表。筛选器为全局状态，任一条件变更后 KPI、趋势、结构、地图与明细表同步刷新；地图与明细表支持按州下钻；RFM 分层筛选可直接把“重要挽留客户”筛成目标名单并导出，供客服直接触达。大屏全 Python 实现，未使用 Power BI、Tableau 或 Fine BI，源码见仓库 05_dashboard.py。

6 商业案例分析

6.1 案例背景

Olist 是巴西代表性的平台型电商服务商，为中小卖家提供统一的线上渠道与物流、支付、客服支持，其公开数据集覆盖 2016-09 至 2018-10 的订单、商品、支付、评价、客户与卖家等多表信息，是研究平台型电商用户行为的常用样本。这一时段正值巴西电商高速扩张，平台订单量从 2017 年 1 月的 800 单增

长到 2018 年 8 月的 6,512 单；但同期客户结构高度“一次性”，窗口内 95,773 名客户中只有 2,975 人（3.11%）有过第二次购买。规模增长与低留存并存，构成本文的案例矛盾：平台究竟由客户价值驱动还是由拉新驱动？一次性买家占主导是否意味着留存策略整体失效，还是存在被平均数掩盖的可挽救子群体？履约体验是否与满意度、沉默存在可检验的关联？围绕这一矛盾，本文以 2017-01-01 至 2018-08-31 为主分析窗口展开分析。

6.2 结果解读

（1）收入由一次性买家主导，复购尚未成为收入支柱：一次性买家占客户数 96.89%、贡献收入 94.19%；复购客户以 3.11%的人数贡献 5.81%的收入，虽人均消费为一次性客户的 1.92 倍，但体量不足以改变结构（表 3、图 5-14）。这修正了“老客贡献主要收入”的常见假设：“高价值客户运营”的对象应从泛化的老客，转向“高价值首购客”。

（2）留存是一条低位水平线，而非衰减曲线：首购后第 1 个月留存 0.51%、第 12 个月 0.18%，12 个月累计复购仅 3.35%（表 4、图 5-15）。问题不是老客慢慢流失，而是绝大多数客户从未被激活为二次购买者；因此留存抓手不在生命周期中后段，而在首购后的第一个季度。

（3）复购高度集中在首购后 90 天：二单间隔中位数 27.9 天，51.09%在 30 天内、68.74%在 90 天内完成（表 4）。一旦首购后 90 天没有产生二单，客户再回来的概率已下降约七成，召回预算应前移而非平均投放。

（4）收入集中度中等偏高，资源需按收入配置：35.44%的客户贡献 70%收入、66.28%贡献 90%，头部 10%客户贡献 38.51%（图 5-16）；品类维度前十合计 62.36%。A 类客户与头部品类应优先获得库存、履约与客服资源，C 类客户（33.72%）应交给自动化。

（5）订单趋势已进入平台期，预测宜作区间预警：2017 年 1 月至 2018 年 8 月累计增长 714%，但 2018 年 1—8 月同比仅增 19.71%，且 3—8 月在 6,167 至 7,211 单之间窄幅波动。模型 6 个月回测 MAPE 5.94%、RMSE 481.5 单，

未来 3 个月点预测 6,428—6,483 单、区间约±27%（表 5、图 5-17），应作为预警而非排产依据。

（6）履约体验是满意度的主导因素：延迟率 6.79%，延迟组均分 2.271、差评率 62.40%、1 分占比 53.80%，而准时组分别为 4.291、9.25%、6.60%（图 5-18）。该差距大于本文考察的其他任何变量，说明“客服话术”类运营难以改善评分，履约才是关键。

模型之间构成递进证据链：RFM 识别“谁值钱”，同期群与二单间隔识别“何时流失”，帕累托识别“资源往哪投”，时间序列识别“趋势是否可持续”，履约分析识别“为何流失”。五者不并列、不交叉重复，共同支撑下一节的建议。

6.3 商业建议（3–5 条，可操作、有数据支撑）

建议一：把“高价值首购客户的二单转化”作为第一优先级。依据：45,306 名高 M 一次性客户（占客户数 47.31%）贡献 75.44%的收入，其中“重要发展客户”23,321 人最近仍有购买行为（R 在中位数以上），是最可能被激活的池子。做法：对首购金额高于 107.27 雷亚尔（M 中位数）的客户，下单后第 7 天推送关联品类推荐、第 30 天发放限时 7 天的二单券、第 60 天做专属客服回访；考核指标从“新增客户数”改为“高客单首购客户 90 天复购率”。

建议二：召回预算集中在首购后 90 天，过期即降级。依据：68.74%的复购发生在首购后 90 天内，90 天后仅余约三成机会；第 1 个月留存 0.51%远高于第 12 个月的 0.18%。做法：首购后 7/30/60/90 天设四档触达（内容推荐、二单券、品类提醒、流失预警），超过 90 天转入低成本自动化池（邮件与站内信），不再投入人工与优惠资源；考核“首购后 90 天复购率”与“二单获客成本”。

建议三：对 22,985 名“重要挽留客户”做定向召回，而非无差别唤醒。依据：该客群占客户数 24.00%、贡献收入 38.06%，人均 261.36 雷亚尔，但

最近一次购买已超过 220 天。做法：按最后购买品类分组，以“同品类新品+免运费”组合触达，两轮无效即移出人工名单；由于沉默期较长，预期响应率低，考核以“召回收入/触达成本”为准，不追求召回人数。

建议四：资源按收入贡献配置，A 类客户与头部品类优先。依据：35.44%的客户贡献 70%的收入，前十品类贡献 62.36%的收入。做法：A 类客户订单优先发货与优先客服；health_beauty、watches_gifts、bed_bath_table 等头部品类在大促优先曝光与备货；C 类客户（33.72%）与长尾品类交给自动化推荐与标准客服，不设人工维护；考核“A 类客户收入占比”与“头部品类缺货率”。

建议五：把延迟交付做成可预警、可补偿的闭环，并以大屏做周度滚动预测。依据：延迟率 6.79%，延迟组差评率 62.40%（准时组 9.25%），1 分占比 53.80%。做法：对预计延迟的订单在承诺日前 48 小时自动致歉并给出新时效，实际延迟订单按延迟天数补偿运费或积分；卖家侧按“首单延迟率”排序，延迟率高的卖家降权；把 ARIMA 周度滚动预测接入大屏，当预测区间下界跌破 6,000 单时触发增长预警；考核“首单延迟率”与“延迟订单的复购率”。

7 结论与展望

7.1 研究结论

本文完成 Olist 多表数据的合规获取、治理、建模与可视化，得到五点结论。第一，收入结构由一次性买家主导：96.89%的客户只买一次、贡献 94.19%的收入，复购客户以 3.11%的人数贡献 5.81%的收入，平台增长是拉新驱动而非客户价值驱动。第二，留存不是“衰减曲线”而是“低位水平线”：第 1 个月留存 0.51%、第 12 个月 0.18%，12 个月累计复购仅 3.35%，问题是“从未被激活”而非“慢慢流失”。第三，68.74%的复购集中在首购后 90 天内，二单间隔中位数 27.9 天，召回窗口应前移到首购后一个季度。第四，收入集中度中等偏高（35.44%的客户贡献 70%收入），A 类客户与头部品类应优

先配置资源。第五，订单量在 2018 年已进入 6,000—7,000 单的平台期，模型 6 个月回测 MAPE 为 5.94%，但并未优于随机游走等朴素基准，预测应定位为区间预警而非精确排产；履约方面，延迟交付率 6.79%、延迟组差评率 62.40%，是满意度最强的单一相关因素。

方法层面，本文验证了“合规获取—治理—模型—模板复现—业务图—交互大屏—商业建议”的端到端流程可复现：12 张模板复现图与 6 张业务模型图全部由 Python 生成，指标与图表由同一份代码产出（附录 A 的 olist_pipeline.py 一键运行），随机种子固定，避免了“图与数不一致”这一课程作业中最常见的失分点。

7.2 局限性与展望

一是样本跨度仅 20 个月，不足两个完整年度周期，季节项无法稳定估计，2018 年 11 月的黑五脉冲落在预测区间之外；未来可引入 Prophet 或带促销事件虚拟变量的 SARIMAX。二是 RFM 阈值仍较粗，F 维度用二值划分牺牲了复购频次的差异，未来可在 F≥2 的子样本内做 K-Means 细分。三是留存与履约分析未控制品类、价格、地区等混杂变量，未来可用生存分析（Cox 模型）或倾向得分匹配估计履约体验对沉默的净效应。四是未使用评论文本与关联规则，未来可用 jieba+snownlp 做情感分析、用 Apriori 挖掘品类组合，为首购推荐提供依据。五是商业建议的增量效果需 A/B 实验验证，可在“90 天四档触达”与“延迟补偿”两个环节设计实验，以复购率、客单价与满意度评估真实增量，形成“分析—建议—实验—迭代”的闭环。

7.3 AI 使用披露（如使用：工具、环节、关键提示词示例）

本文使用 AI 编程助手辅助完成三类工作：代码框架与函数模板（清洗函数、Matplotlib 样式函数）、论文语言润色与结构调整、指标口径的交叉核对。关键提示词示例：“按课程评分标准生成 Olist 多表清洗与 RFM 八分类代码，F 维度用 1 与≥2 二值划分并说明理由”“用 Matplotlib 复现同期群留存热力图，

中文标签、色标上限取 99 分位”“检查论文中所有数值是否与 metrics.json 一致”。所有数据计算、模型选型判断、结论提炼与结果复核由作者完成；AI 未用于生成或修改任何数据，文中全部数值均可由附录代码复现。

参考文献

[1] Olist. Brazilian E-Commerce Public Dataset by Olist[DB/OL]. Kaggle, 2018. https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce.

[2] Hughes A M. Strategic Database Marketing[M]. 3rd ed. New York: McGraw-Hill, 2005.

[3] Fader P S, Hardie B G S, Lee K L. RFM and CLV: Using Iso-Value Curves for Customer Base Analysis[J]. Journal of Marketing Research, 2005, 42(4): 415-430.

[4] Hyndman R J, Athanasopoulos G. Forecasting: Principles and Practice[M]. 3rd ed. Melbourne: OTexts, 2021.

[5] Excel 数据可视化：从图表到数据大屏. 课程指定教材

附录

A 核心代码片段

完整代码见仓库 scripts/ 目录，以下为与本文结论直接相关的核心片段；所有片段均来自实际运行文件 olist_pipeline.py，缩进与注释保持原样。

A.1 环境依赖与一键复现入口

```
# ---------- requirements.txt ----------
pandas==2.2.2     numpy==1.26.4     matplotlib==3.8.4
statsmodels==0.14.2     plotly==5.22.0     streamlit==1.35.0


# ---------- run_all.py ----------
import subprocess, sys
STEPS = ["scripts/01_load.py", "scripts/02_clean.py",
        "scripts/03_analysis.py", "scripts/04_visuals.py",
        "scripts/05_dashboard.py"]
for s in STEPS:
    print("[run]", s)
    subprocess.run([sys.executable, s], check=True)
```

```
# 也可直接运行管线：python olist_pipeline.py --raw data/raw --out outputs
```

A.2　读取与清洗（缺失 / 重复 / 逻辑异常）

```
def clean(df):
    orders, products, reviews = df["orders"], df["products"], df["reviews"]
    # 邮编前缀转字符串，避免前导零丢失
    df["customers"]["customer_zip_code_prefix"] = \
        df["customers"]["customer_zip_code_prefix"].astype(str)
    # 缺失：品类名缺失 610 条，填充 unknown 并单列展示
    products["product_category_name"] = \
        products["product_category_name"].fillna("unknown")
    # 重复：同一订单保留最新一条评价（涉及 1,603 行）
    reviews = (reviews.sort_values(["order_id", "review_creation_date"])
              .drop_duplicates("order_id", keep="last"))
    # 逻辑异常：送达早于下单（本例 0 条），置空后不计入时效
    bad = (orders["order_delivered_customer_date"]
           < orders["order_purchase_timestamp"])
    orders.loc[bad, "order_delivered_customer_date"] = pd.NaT
    df.update(orders=orders, products=products, reviews=reviews)
    return df
```

A.3　订单级宽表构建（多表关联与派生指标）

```
def build_fact(df):
    it = df["items"].merge(df["products"][["product_id",
                    "product_category_name"]], on="product_id", how="left")
    it = it.merge(df["trans"], on="product_category_name", how="left")
    it["product_category_name_english"] = \
        it["product_category_name_english"].fillna("unknown")
    item_ord = it.groupby("order_id", as_index=False).agg(
        item_count=("order_item_id", "count"),
        gmv_items=("price", "sum"), freight=("freight_value", "sum"))
    # 支付表先按订单聚合再连接，防止一单多支付导致行膨胀
    pay_ord = df["payments"].groupby("order_id", as_index=False).agg(
        payment_value=("payment_value", "sum"),
        payment_installments=("payment_installments", "max"))
    od = (df["orders"].merge(df["customers"], on="customer_id", how="left")
          .merge(item_ord, on="order_id", how="left")
          .merge(pay_ord, on="order_id", how="left")
          .merge(df["reviews"][["order_id", "review_score"]],
                 on="order_id", how="left"))
    od["order_total_value"] = od["gmv_items"].fillna(0) + od["freight"].fillna(0)
    od["delivery_days"] = (od["order_delivered_customer_date"]
                           - od["order_purchase_timestamp"]).dt.days
    od["delay_days"] = (od["order_delivered_customer_date"]
                        - od["order_estimated_delivery_date"]).dt.days
    od["is_late"] = (od["delay_days"] > 0).astype("Int64")
    return od, it
```

A.4　RFM 八分类（中位数阈值 + F 二值划分）

```
SEG_MAP = {(True, True, True): "重要价值客户", (False, True, True): "重要保持客户",
           (True, False, True): "重要发展客户", (False, False, True): "重要挽留客户",
           (True, True, False): "一般价值客户", (False, True, False): "一般保持客户",
           (True, False, False): "一般发展客户", (False, False, False): "一般挽留客户"}


def rfm(w, cutoff=pd.Timestamp("2018-08-31")):
    c = w.groupby("customer_unique_id").agg(
        last=("order_purchase_timestamp", "max"),
        F=("order_id", "nunique"), M=("order_total_value", "sum"),
        first=("order_purchase_timestamp", "min"))
```

```
    c["R"] = (cutoff - c["last"]).dt.days
    r_med, m_med = c["R"].median(), c["M"].median()   # 220 天、107.27 雷亚尔
    # F 不用中位数：其中位数为 1，改用 1 与 >=2 二值划分以保留区分度
    c["R_high"], c["F_high"], c["M_high"] = (c.R >= r_med, c.F >= 2,
                                             c.M >= m_med)
    c["seg"] = [SEG_MAP[(a, b, d)] for a, b, d in
                zip(c.R_high, c.F_high, c.M_high)]
    return c, r_med, m_med


def rfm_summary(c):
    s = c.groupby("seg").agg(customers=("M", "size"), revenue=("M", "sum"))
    s["cus_share"] = 100 * s.customers / s.customers.sum()
    s["rev_share"] = 100 * s.revenue / s.revenue.sum()
    s["arpu"] = s.revenue / s.customers
    return s.sort_values("revenue", ascending=False)
```

A.5　同期群留存矩阵与二单间隔

```
def cohort_matrix(w, c, end=pd.Period("2018-08", "M"), kmax=12):
    c["cohort"] = c["first"].dt.to_period("M")
    o = w.merge(c[["cohort"]], left_on="customer_unique_id",
                right_index=True, how="left")
    o["k"] = o["purchase_ym"].astype("int64") - o["cohort"].astype("int64")
    size = c.groupby("cohort").size()
    act = o[o.k >= 0].groupby(["cohort", "k"]).customer_unique_id.nunique()
    mat = pd.DataFrame(index=size.index, columns=range(kmax + 1), dtype=float)
    for coh in size.index:            # 未观测满 k 个月的同期群留空
        for k in range(min(kmax, end.ordinal - coh.ordinal) + 1):
            mat.loc[coh, k] = 100 * act.get((coh, k), 0) / size[coh]
    return mat, size


def repurchase_gap(w):                # 首购至第二单的间隔天数
    o = w.sort_values(["customer_unique_id", "order_purchase_timestamp"]).copy()
    o["rk"] = o.groupby("customer_unique_id").cumcount()
    f1 = o[o.rk == 0][["customer_unique_id", "order_purchase_timestamp"]] \
        .rename(columns={"order_purchase_timestamp": "t1"})
    s2 = o[o.rk == 1][["customer_unique_id", "order_purchase_timestamp"]] \
        .rename(columns={"order_purchase_timestamp": "t2"})
    g = s2.merge(f1, on="customer_unique_id", how="inner")
    return (g["t2"] - g["t1"]).dt.total_seconds() / 86400   # 90 天内占 68.74%
```

A.6　帕累托 / ABC 分类

```
def pareto(c):
    """累计收入占比：35.44% 的客户贡献 70%，66.28% 贡献 90%。"""
    s = c["M"].sort_values(ascending=False).reset_index(drop=True)
    cum = s.cumsum() / s.sum()
    out = {p: round(100 * ((cum <= p / 100).sum() + 1) / len(cum), 2)
           for p in (70, 80, 90)}
    return s, cum, out
```

A.7　时间序列选型、回测与预测

```
import statsmodels.api as sm


def fit_forecast(y, h=3):
    """y 为 2017-01—2018-08 的月度订单量（20 点），回测取最后 6 个月。"""
    kw = dict(order=(1, 1, 1), seasonal_order=(0, 0, 0, 12),
              enforce_stationarity=False, enforce_invertibility=False)
    ytr, yte = y[:-6], y[-6:]
    r = sm.tsa.statespace.SARIMAX(ytr, **kw).fit(disp=False)
    fc = r.get_forecast(6)
```

```
    pred = np.asarray(fc.predicted_mean, float)
    lo, hi = np.asarray(fc.conf_int(alpha=.05)).reshape(-1, 2).T
    mape = np.mean(np.abs((yte - pred) / yte)) * 100    # 5.94%
    rmse = np.sqrt(np.mean((yte - pred) ** 2))          # 481.5 单
    full = sm.tsa.statespace.SARIMAX(y, **kw).fit(disp=False)
    f3 = full.get_forecast(h)
    return dict(mape=mape, rmse=rmse, pred=pred, lo=lo, hi=hi,
                point=np.asarray(f3.predicted_mean, float),
                ci3=np.asarray(f3.conf_int(alpha=.05)).reshape(-1, 2))

# 选型对照：ARIMA(2,1,2) 的 AIC 更低（172.84）但回测 MAPE 达 33.28%，
# 属过拟合；故以回测误差而非 AIC 定为 ARIMA(1,1,1)。
```

A.8 Streamlit 交互式大屏（骨架）

```
import streamlit as st
st.set_page_config(layout="wide", page_title="Olist 商业分析大屏")


orders = load_clean("data/clean/orders_clean.csv")  # 清洗后订单宽表
seg = load_table("outputs/tables/rfm_segments.csv")


# 全局筛选器：任一条件变化后，下方 KPI 与所有图表同步刷新
c1, c2, c3 = st.columns(3)
states = c1.multiselect("州", sorted(orders.customer_state.unique()))
dates = c2.date_input("日期范围", [orders.purchase_date.min(),
                                   orders.purchase_date.max()])
segs = c3.multiselect("RFM 分层", list(seg.seg), default=list(seg.seg))


df = orders[orders.customer_state.isin(states)] if states else orders
df = df[(df.purchase_date >= pd.Timestamp(dates[0])) &
        (df.purchase_date <= pd.Timestamp(dates[-1]))]
df = df.merge(seg, on="customer_unique_id", how="left")
df = df[df.seg.isin(segs)] if segs else df


k1, k2, k3, k4 = st.columns(4)
k1.metric("订单数", f"{df.order_id.nunique():,}")
k2.metric("客户数", f"{df.customer_unique_id.nunique():,}")
k3.metric("GMV（万雷亚尔）", f"{df.order_total_value.sum() / 1e4:,.0f}")
k4.metric("延迟率", f"{df.is_late.mean():.2%}")
st.plotly_chart(monthly_trend(df))      # 月度趋势
st.plotly_chart(rfm_structure(df))      # RFM 八分类结构
st.plotly_chart(cohort_heatmap(df))     # 同期群留存
st.plotly_chart(state_map(df))          # 州级地图
st.dataframe(df[["order_id", "customer_state", "order_total_value",
                 "delivery_days", "is_late"]].head(200))  # 明细表下钻
```

B Gitee/github 仓库链接与目录结构

仓库地址：[hzx371/assignment: smr]

```
Business-Analysis-Visual/
├── data/
│   ├── raw/              9 个官方 CSV（未改动，可追溯）
│   ├── clean/            orders_clean.csv、customers_clean.csv 等
│   └── schema.md         字段字典与主外键说明
├── scripts/
│   ├── 01_load.py        读取与校验
│   ├── 02_clean.py       清洗、派生、导出 CSV / SQLite
│   ├── 03_analysis.py    RFM / 同期群 / 帕累托 / 时间序列
│   ├── 04_visuals.py     fig01—fig33 批量出图
│   └── 05_dashboard.py   Streamlit 大屏
```

```
├── outputs/
│   ├── figures/          fig01 — fig33（200 dpi，命名规范）
│   └── tables/           metrics.json、rfm_segments.csv 等
├── docs/                 期末大论文、数据来源合规声明
├── requirements.txt
├── run_all.py            一键复现入口
└── README.md             项目简介、数据来源、复现步骤、图表索引、分工说明
```

C　图表索引

正文共含 18 张图（12 张模板复现图 + 6 张业务模型图），均可由仓库 04_visuals.py 一键重建，文件名与仓库 outputs/figures/一致。

表 C-1　图表索引与对应关系

正文图号	仓库编号	图表名称	类别与对应关系
图 5-1	fig01	渐变柱形图	模板复现·柱形类
图 5-2	fig02	带均值柱形图	模板复现·柱形类
图 5-3	fig03	渐变圆角柱形图	模板复现·柱形类
图 5-4	fig04	标注柱形图	模板复现·柱形类
图 5-5	fig06	蝴蝶图	模板复现·柱形类
图 5-6	fig10	平滑折线图	模板复现·折线类
图 5-7	fig11	菱形走势图	模板复现·折线类
图 5-8	fig12	对比折线图	模板复现·折线类
图 5-9	fig13	单值圆环图	模板复现·饼环类
图 5-10	fig16	玉玦图	模板复现·饼环类
图 5-11	fig19	仪表盘图	模板复现·仪表盘类
图 5-12	fig26	滑珠图	模板复现·滑珠类
图 5-13	fig28	RFM 客户价值分布散点	业务模型·RFM
图 5-14	fig29	RFM 八分类收入贡献	业务模型·RFM
图 5-15	fig30	同期群留存热力图	业务模型·同期群
图 5-16	fig31	客户收入帕累托曲线	业务模型·帕累托/ABC
图 5-17	fig32	订单量回测与预测	业务模型·时间序列
图 5-18	fig33	准时与延迟交付评分构成	业务模型·履约分析

说明：仓库共生成 33 张图，其余 15 张（fig05、07、08、09、14、15、17、18、20—25、27）为同批复现成果，按“不必堆数量”的原则未在正文重复展示，可在仓库 outputs/figures/查阅。